SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Sybil napadi u društvenim mrežama i zaštita od njih

Antun Razum
Voditelj: *prof. dr. sc. Siniša Srbljić*

Zagreb, svibanj 2016.

SADRŽAJ

1. Uvod **1**

2. Sybil napadi **2**

2.1. Povijest i motivacija 2

2.1.1. Središnji autoritet 2

2.1.2. Izazovi u decentraliziranim pristupima 3

2.2. Pojmovi i definicije 3

2.2.1. Model sustava 3

2.2.2. Slučajne šetnje i vrijeme miješanja 4

3. Obrana od sybil napada **5**

3.1. Pretpostavke 5

3.2. Algoritam 6

3.2.1. Algoritam za identifikaciju sybil čvorova 6

3.2.2. Algoritam za pronalazak sybil grupa 8

4. Rezultati postojećeg rješenja **10**

5. Zaključak **11**

6. Literatura **12**

1. Uvod

Sybil napadi (engl. *Sybil attacks*) su dobro poznata vrsta napada u distribuiranim sustavima poput senzorskih i *peer-to-peer* mreža. U osnovnom obliku ovog napada napadač stori velik broj lažnih identiteta preko kojih utječe na ponašanje napadnutog sustava. Broj identiteta koji napadač može stvoriti ovisi o napadačevim resursima kao što su propusnost mreže, memorija i računarna moć.

2. Sybil napadi

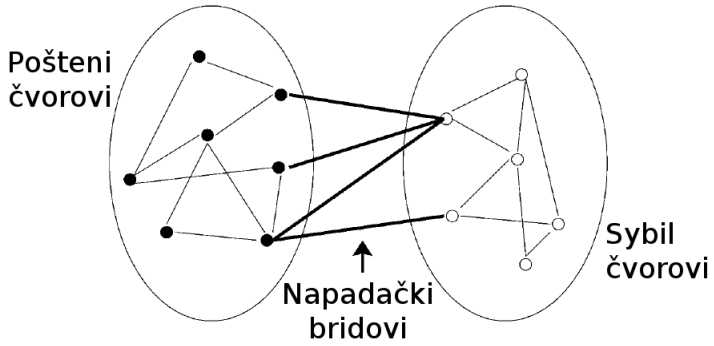

Slika 2.1: Napadački bridovi u grafu društvene mreže

2.1. Povijest i motivacija

2.1.1. Središnji autoritet

Sybil napadi mogu se lagano kontrolirati pomoću pouzdranog središnjeg autoriteta koji izdaje i provjerava podatke jedinstvene stvarnom čovjeku. Na primjer, ako sustav zahtijeva registraciju korisnika pomoću broja osobne iskaznice ili vozačke dozvole, onda prepreka za sybil napade postaje puno viša. Autoritet također može zahtijevati i plaćanje za registraciju. Nažalost, postoje mnogi slučajevi gdje takvi sustavi nisu poželjni. Na primjer, može biti teško izabrati jedinstveni autoritet kome mogu vjerovati svi korisnici na svijetu. Nadalje, taj središnji autoritet može lako postati točka zatajenja (engl. *single point of failure*) – meta *denial-of-service* napada ili usko grlo u izvođenju sustava. Na poslijetku, plaćanje registracije ili traženje osjetljivih informacija prilikom iste odbilo bi velik broj korisnika. Jedini način da se ovi problemi izbjegnu je distribuiranost sustava za provjeru. [4]

2.1.2. Izazovi u decentraliziranim pristupima

Obrana od sybil napada bez puzdanog središnjeg autoriteta puno je teža. Puno decentraliziranih sustava pokušavalo se boriti protiv sybil napada povezivanjem identiteta korisnika s IP adresom. No, napadačima još tada korištenjem određenih metoda nije bio problem ukrasti i iskoristiti veći broj IP adresa s kojih mogu djelovati. [2] Osim krađe IP adresa, napadač može preuzeti veći broj korisničkih računala tako stvarajući *botnet* sačinjen od tisuća računala diljem svijeta. Mnogi drugi decentralizirani načini obrane također su se pokazali neuspješnima. Primjerice zagonetke koje zahtijevaju ljudski napor, kao što je *CAPTCHA*, napadač može upotrijebiti na svojoj stranici tražeći od korisnika njegove stranice da ih riješe. Sve to vodi do zaključka kako se obrana od napada ne može temeljiti na jednokratnim provjerama prilikom registracije korisnika na sustav, već na temeljitoj analizi grafa društvene mreže te ispitivanju na raznih algoritamskih svojstava grafa. [4]

2.2. Pojmovi i definicije

2.2.1. Model sustava

Društvena mreža promatra se kao neusmjereni bezteţinski graf $G = (V, E)$. Čvorovi predstavljaju korisnike mreže, a bridovi određenu vrstu odnosa između korisnika. Vrijedi $|V| = n, V = v_1, v_2, ..., v_n$ te $|E| = m$, gdje je $e_{ij} \in E$ tj. $v_i \to v_j$ ako je $v_i \in V$ susjedan $v_j \in V$, za $1 \leq i, j \leq n$. Matrica $A = [a_{ij}]^{n \times n}$ naziva se matrica susjedstva gdje je $a_{ij} = 1$ ako je $e_{ij} \in E$ i $a_{ij} = 0$ ako nije. Matrica $P = [p_{ij}]^{n \times n}$ naziva se matrica prijelaza (engl. *transition matrix*)

$$p_{ij} = \begin{cases} \frac{1}{deg(v_i)} & e_{ij} \in E \\ 0 & inace \end{cases} \tag{2.1}$$

gdje je $deg(v_i)$ stupanj čvora v_i. Skup susjeda čvora v_i označava se s $N(v_i)$ tako da je $deg(v_i) = |N(v_i)|$.

U mreži se nalazi određeni broj *poštenih čvorova* (engl. *honest nodes*), svaki sa svojim identitetom, koji predstavljaju stvarne korisnike mreže. Također postoji jedan ili više napadača u mreži, svaki s određenim brojem lažnih identiteta koji su u grafu predstavljeni *sybil čvorovima*. Bridovi između sybil čvorova i poštenih čvorova nazivaju se *napadački bridovi* (engl. *attack edges*). *Sybil regija* (engl. *sybil region*) sastoji se od svih sybil čvorova, a *poštena regija* (engl. *honest region*) sastoji se od svih po-

štenih čvorova. Sve sybil čvorove kontrolira napadač. Stoga, napadač može stvoriti proizvoljan broj bridova unutar sybil regije.

2.2.2. Slučajne šetnje i vrijeme miješanja

Prijelaz između dva čvora u grafu može se prikazati markovljevim lancem (ML) koji predstavlja slučajnu štetnju kroz graf G. *Slučajna šetnja* duljine w preko G je niz čvorova u G koji počinje čvorom v_i i završava čvorom v_t. ML je ergodičan (engl. *ergodic*) ako je ireducibilan i aperiodičan, što znači da ima stacionarnu distribuciju π i distribucija poslije slučajne šetnje duljine w konvergira prema π kada $w \to \infty$. Stacionarna distribucija ML je distribucija koja je invarijantna s obrizorm na matricu prijelaza P tj. $\pi P = \pi$. *Vrijeme miješanja* (engl. *mixing time*) ML definira se kao najmanja duljina slučajne šetnje kojom se postiže stacionarna distribucija. Formalno i preciznije, ovu definiciju možemo izreći na sljedeći način:

$$T(\epsilon) = \max_i \min\{t : |\pi - \pi^{(i)}P^t|_1 < \epsilon\} \tag{2.2}$$

gdje je π stacionarna distribucija, $\pi^{(i)}$ početna distribucija koncentrirana na čvoru v_i, P^t matrica prijelaza nakon t koraka, a $|\cdot|_1$ ukupna varijacijska udaljenost, definirana kao $\frac{1}{2}\sum_j |\pi_j - \pi_j^{(i)}|$. Za ML kažemo da je *brzo miješajući* (engl. *rapidly mixing, fast mixing*) ako je $T(\epsilon) = O(\log n)$. [1]

Teorem o stacionarnoj distribuciji: Za neusmjereni bezteži̇nski graf G, stacionarna distribucija ML preko G je vektor $\pi = [\pi_{v_i}]$ gdje je $\pi_{v_i} = \frac{deg(v_i)}{2m}$ tj. $\pi = [\frac{deg(v_1)}{2m}\frac{deg(v_2)}{2m}\ldots\frac{deg(v_n)}{2m}]$.

Uz pomoć prethodnog teorema može se dokazati da je vrijeme miješanja u korelaciji s povezanošću grafa. Dobro povezani grafovi imaju malo vrijeme miješanja, dok slabo povezani grafovi imaju veće vrijeme miješanja. [1]

3. Obrana od sybil napada

3.1. Pretpostavke

Algoritmi za obranu od sybil napda temelje se na sljedećim pretpostavkama za koje se pokazalo da vrijede u stvarnim društvenim mrežama [3]:

Poštena regija je brzo miješajuća. Kao što je definirano u prethodnom poglavlju, to znači da vrijedi $T(\epsilon) = O(\log n)$, za funkciju vremena miješanja definiranu prema jednadžbi 2.2. Slučajne šetnje u brzo miješajućim grafovima općenito brzo konvergiraju ka stacionarnoj distribuciji. [3] Pokazano je da su stvarne društvene mreže brzo miješajuće. [5]

Jedan poznat pošteni čvor. U grafu postoji barem jedan poznati pošteni čvor. Iz tog čvora kreće potraga za sybil čvorovima.

Administratoru je poznata topologija društvene mreže. Ovo povlači tvrdnju da je algoritam centraliziran. Budući da su sve današnje društvene mreže pod centraliziranom kontrolom, može se pretpostaviti da su administratori tih mreža ti koji brinu za sigurnost sustava pa tako i obranu od sybil napada.

Veličina sybil regije nije usporediva s veličinom poštene regije. Uz današnje veličine društvenih mreža (npr. Facebook preko 1,6 milijardi), može se pretpostaviti da je napadaču nemoguće stvoriti toliko sybil identiteta. To je tim više otežano uobičajenim postupcima provjere korisnika kao što su potvrda e-mail adrese, unos osobnih informacija te rješavanje CAPTCHA-e.

Broj napadačkih bridova je ograničen. Kao posljedica, kada napadač stvori veći broj sybil čvorova, postojat će nepropocijonalno mali *rez* (rezni skup) između poštene i sybil regije. Postojanje malog reza narušava svojstvo brzog miješanja: miješanje između poštenih čvorova je brzo, dok je miješanje između poštenih i sybil čvorova sporo.

3.2. Algoritam

Cjelokupni algoritam sastoji se od dvije osnovne komponente: algoritma za identifikaciju sybil čvorova i algoritma za pronalazak sybil grupa.

3.2.1. Algoritam za identifikaciju sybil čvorova

Algoritam za identifikaciju sybil čvorova prima graf društvene mreže $G(V, E)$, poznati pošteni čvor h i *osumnjičeni čvor* (engl. *suspect node*) u kao ulaz, a vraća je li čvor u uistinu syibil čvor ili ne. Algoritam se temelji na slučajnim šetnjama. Slučajna šetnja na grafu definirana je nizom prijelaza između čvorova grafa G. Ako je šetnja u nekom koraku na čvoru v_i, onda je vjerojatnost da će se šetnja nastaviti preko brida $v_i \rightarrow v_j$ jednaka $\frac{1}{deg(v_i)}$ prema jednadžbi 2.1.

Intuicija algoritma je sljedeća: budući da je rez između poštene i sybil regije mali, slučajne šetnje koje polaze od sybil čvorova u pravilu će zapeti u sybil regiji. Također, zbog pretpostavke o neusporedivosti veličine sybil regije i poštene regije, broj čvorova prijeđenih slučajnm šetnjama iz poštenih čvorova bit će veći od broja čvorova prijeđenih šetnjama iz sybil čvorova sve dok su šetnje dovoljno dugačke i dok je broj šetnji dovoljno velik da se ta razlika istakne. Poradi daljnjih objašnjenja, broj prijelaza skupa slučajnih šetnji preko određenog čvora definira se kao *frekvencija* tog čvora. Valja primijetiti da neki čvor može biti prijeđen više puta u jednoj šetnji.

Algoritam za identifikaciju sybil čvorova sastoji se od dvije faze prikazane u algoritmima 3.1 i 3.2. Prva faza prima graf G i h kao ulaze i vraća pragove koje koristi druga faza kako bi identificirala sybil čvorove. Prva se faza treba pozvati samo jednom za cijeli graf društvene mreže. Kao što je pokazano u algoritmu 3.1, algoritam prvo napravi f kratkih slučajnih štetnji duljine $l_s = \log n$ iz poznatog poštenog čvora h. f konačnih čvorova ravna se prema stacionarnoj distribuciji poštene regije zbog pretpostavke o brzom miješanju poštene regije. Konačni su čvorovi stoga pošteni s velikom vjerojatnošću. [4] Poslije ovoga poznati pošteni čvor h i f konačnih čvorova koriste se kao *čvorovi sudci* od kojih algoritam postavlja kriterije za identifikaciju sybil čvorova. Valja primijetiti da mogućnost pojavljivanja sybil čvorova među čvorovima sudcima ne utječe na učinkovitost algoritma zbog njihovog veoma ograničenog broja. Počevši od najmanje duljine l_{min} do najaveće l_{max} s razlikama od 100 za svaku duljinu l, algoritam radi R (od 1,000 do 2,000) slučajnih šetnji polazeći od svakog čvora sudca. Pritom broji čvorove čija frekvencija nije manja od praga t (koji je mala konstatna, npr. 5). Algoritam pronađe $f + 1$ takvu vrijednost za svaku duljinu l. Zatim izračuna srednju

vrijednost i stadnardnu devijaciju tih vrijednosti i ispiše trojku $(l, srVr, stdDev)$.

Algoritam 3.1: Računanje pragova

```
1  function pretprocesiranje(G, h) begin
2      J = {h};
3      for i = 1 to f do
4          Napravi slučajnu šetnju duljine l_s = log n od čvora h;
5          J = J ∪ {posljenji čvor slučajne šetnje};
6      l = l_min;
7      while l ≤ l_max do
8          forall i ∈ J do
9              Napravi R slučajnih šetnji duljine l iz čvora i;
10             n_i = broj čvorova s frekvencijom ne manjom od t;
11         ispis(l, srVr({n_i : i ∈ J}), stdDev({n_i : i ∈ J}));
12         l = l + 100;
```

Kao što je pokazano u algoritmu 3.2, kako bi se odredilo je li čvor u sybil čvor, algoritma prvo napravi R slučajnih šetnji početne duljine $l = l_0$ iz čvora u. l_0 je veći ili jedak duljini l_{min} korištenoj u algoritmu 3.1. Algoritam zatim uspoređuje broj čvorova čija frekvencija nije maja od t sa srednjom vrijednosti $srVr$ iz trojke $(l, srVr, stdDev)$ ispisane u algoritmu 3.1. Ako je razlika srednje vrijednosti i broja prebrojenih čvorova veća od $stdDev \cdot \alpha$ (α je konstanta, npr. 20), čvor u smatra se sybil čvorom i algoritam završava. Inače, algoritam udvostručuje l i ponavlja proces sve dok l nije veća od l_{max}. Ako tada u i dalje nije identificiran kao sybil čvor, on se tada smatra poštenim i algoritam se završava.

Neka je dan graf društvene mreže $G(V, E)$ i poznati pošteni čvor h, najveća duljina slučajne šetnje l_{max} preko koje se odlučuje kada će se završiti algoritam može se odrediti na sljedeći način. Napravi se R slučajnih šetnji iz h duljine l_{max}. Broj čvorova s frekvencijom ne manjom od t mora biti veći od $\frac{|V|}{2}$. Kako je sybil regija manja od poštene regije, l_{max} određena na ovaj način je dovoljno velika da R slučajnih šetnji iz sybil čvora pokrije sybil regiju kako bi se istakla razlika između slučajnih šetnji iz poštenog i sybil čvora. Algoritam ispituje osumnjičeni čvor svaki puta udvostručujući duljinu slučajne šetnje. Ovo omogućuje pronalazak sybil čvorova u sybil regijama različitih veličina: za male regije dovoljne su krake šetnje, dok su za one veće potrebne dulje šetnje jer bi otisak kratkih slučajnih šetnji u syibil regiji mogao biti isti kao i u poštenoj regiji.

Algoritam 3.2: Identifikacija sybil čvorova

```
1  function identifikacija(G, u, trojke) begin
2      l = l_0;
3      while l ≤ l_max do
4          Napravi R slučajnih šetnji dulje l iz u;
5          m = broj čvorova čija frekvencija nije manja od t;
6          (l, srVr, stdDev) = trojka iz trojke koja odgovara duljini l;
7          if srVr − m > stdDev · α then
8              return true;
9          l = 2 · l;
10     return false;
```

3.2.2. Algoritam za pronalazak sybil grupa

Nakon što se prepozna jedan sybil čvor potrebno je odrediti sybil grupu koja ga okružuje. Algoritam za pronalazak sybil grupe prima graf društvene mreže $G(V, E)$ i poznati sybil čvor s te vraća sybil grupu koja okružuje dani čvor. Sybil grupa definira se kao pograf grafa G koji se sastoji samo od sybil čvorova u kojemu ne postoji mali rez.

Algoritam pronalaska sybil grupe temelji se na *djelomičnim* slučajnim šetnjama iz s. Djelomične slučajne šetnje ponašaju se isto kao i *jednostavne* slučajne šetnje korištene u prethodnom poglavlju, osim što ne prolaze istim čvorovima. Zbog toga, kada djelomična šetnja dođe do čvora čije je sve susjede već prošla, ta je djelomična šetnja *mrtva* i ne može se nastaviti. Zbog ovog svojstva djelomične slučajne šetnje koje polaze iz sybil čvorova teže će izaći iz sybil grupe, u usporedbi s jednostavnim šetnjama, jer one *umiru* kada god dođu do ruba sybil grupe. Slično kao i algoritam za identifikaciju sybil čvorova, ovaj se algoritam temelji na činjenici da će djelomične slučajne šetnje iz sybil čvorova najčešće ostati u sybil regiji.

Sam algoritam također se sastoji od dvije faze kao i algoritam za identifikaciju sybil čvorova. Zadaća prve faze procjena duljine djelomičnih slučajnih šetnji u drugoj fazi. Algoritam počinje nekom duljinom l_0 i radi R djelomičnih slučajnih šetnji. Zatim izračunava omjer mrtvih šetnji i uspoređuje ga s zadanom konstanom β (broj blizu 1, npr. 0.95). Ako je omjer manji od β, duljina šetnje se udvostručuje i algoritam se nastavlja. Ovo se ponavlja sve dok omjer mrtvih šetnji nije dovoljno velik. Ideja algoritma je da će broj neobiđenih čvorova u sybil grupi biti vrlo mali ako je broj mrtvih šetnji blizu 1.

Druga faza algoritma osigurava da se u pronađenoj grupi ne nađu pošteni čvorovi.

To se može dogoditi jer neke djelomične slučajne šetnje mogu proći mali rez između sybil grupe i poštene regije te proći kroz veliki broj poštenih čvorova. Kako bi se ovo postiglo, algoritam koristi mjeru*provodljivosti* (engl. *conductance*). Provodljivost nekog grafa $S(V, E)$ definira se na sljedeći način:

$$d = \sum_{v \in V} deg(v)$$

$$a = |\{\{a, b\} \in E : a \in V \wedge b \notin V\}|$$

$$provodljivost(S) = \frac{a}{d}$$

d je dakle zboj stupnjeva svih čvorova u S, a a broj bridova s jednim vrhom u S a drugim u $\overline{S}$. Provodljivost grafa S je omjer a i d. Provodljivost je stoga mjera kvalitete reza između S i $\overline{S}$: što je manja to je rez manji.

Algoritam u drugoj fazi napravi R djelomičnih slučajnih šetnji iz poznatog sybil čvora s duljine određene u prvoj fazi algoritma. Zatim se prijeđeni čvorovi sortiraju prema frekvenciji te se njima prolazi u silaznom poretku. Prolazeći kroz čvorove stvara se skup S. Neki se čvor dodaje u skup ako se njegovim dodavanjem provodljivost skupa ne povećava. Nakon što se prođu svi čvorovi, algoritam zabilježi trenutnu vrijednost provodljivosti te ponavlja postupak. Ovo se ponavlja sve dok provodljivost nakon iteracije po čvorovima ostane nepromijenjena.

4. Rezultati postojećeg rješenja

Tablica 4.1: Rezultati SybilDefender algoritma. 10,000 sybil čvorova, 1,000 napadačkih bridova

R	Orkut				Facebook			
	PA model		ER model		PA model		ER model	
	F^+	F^-	F^+	F^-	F^+	F^-	F^+	F^-
1000	0	0.02%	0	0.28%	0	0.22%	0.1%	0.54%
1500	0	0.02%	0	0.32%	0.3%	0.12%	0.2%	0.44%
2000	0	0	0	0.22%	0.5%	0.04%	0.5%	0.4%

5. Zaključak

6. Literatura

[1] A. Mohaisen, N. Hopper, i Y. Kim. Keep your friends close: Incorporating trust into social network-based sybil defenses. U *INFOCOM, 2011 Proceedings IEEE*, stranice 1943–1951, April 2011. doi: 10.1109/INFCOM.2011.5934998.

[2] Anirudh Ramachandran i Nick Feamster. Understanding the network-level behavior of spammers. *SIGCOMM Comput. Commun. Rev.*, 36(4):291–302, Kolovoz 2006. ISSN 0146-4833. doi: 10.1145/1151659.1159947. URL `http://doi.acm.org/10.1145/1151659.1159947`.

[3] W. Wei, F. Xu, C. C. Tan, i Q. Li. Sybildefender: A defense mechanism for sybil attacks in large social networks. *IEEE Transactions on Parallel and Distributed Systems*, 24(12):2492–2502, Dec 2013. ISSN 1045-9219. doi: 10.1109/TPDS.2013.9.

[4] H. Yu, M. Kaminsky, P. B. Gibbons, i A. D. Flaxman. Sybilguard: Defending against sybil attacks via social networks. *IEEE/ACM Transactions on Networking*, 16(3):576–589, June 2008. ISSN 1063-6692. doi: 10.1109/TNET.2008.923723.

[5] H. Yu, P. B. Gibbons, M. Kaminsky, i F. Xiao. Sybillimit: A near-optimal social network defense against sybil attacks. *IEEE/ACM Transactions on Networking*, 18 (3):885–898, June 2010. ISSN 1063-6692. doi: 10.1109/TNET.2009.2034047.

Sybil napadi u društvenim mrežama i zaštita od njih

Sažetak

Sybil napad je napad kojim se pokušava srušiti sustav reputacije stvaranjem lažnih identiteta u peer-to-peer mrežama koji djeluju na slican način. Društvene mreže su vrlo česta meta sybil napada. Zaštita od sybil napada na društevnim mrežama temelji se na algoritamskim svojstvima grafova društevnih mreža putem kojih se računa razina povjerenja koja se može pridijeliti proizvoljnom čvoru grafa.

Ključne riječi: društvene mreže, sybil napad, teorija grafova, sigurnost podataka, idenditet